

	<p>Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования «Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)</p>
---	---

ФАКУЛЬТЕТ Информатика и системы управления

КАФЕДРА Программное обеспечение ЭВМ и информационные технологии

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №6 **«ОБРАБОТКА ДЕРЕВЬЕВ, ХЕШ-ФУНКЦИЙ»**

Студент Егорова Полина Александровна

Группа ИУ7 – 34Б

Преподаватель Барышникова Марина Юрьевна

ЦЕЛЬ РАБОТЫ

Цель работы – построить дерево, вывести его на экран в виде дерева, реализовать основные операции работы с деревом: обход дерева, включение, исключение и поиск узлов, сбалансировать дерево, сравнить эффективность алгоритмов сортировки и поиска в зависимости от высоты деревьев и степени их ветвления; построить хеш-таблицу и вывести ее на экран, устранить коллизии, если они достигли указанного предела, выбрав другую хеш-функцию и реструктуризировав таблицу; сравнить эффективность поиска в сбалансированных деревьях, в двоичных деревьях поиска (ДДП), в хеш-таблицах и в файлах. Сравнить эффективность реструктуризации таблицы для устранения коллизий и поиска в ней с эффективностью поиска в исходной таблице.

ОПИСАНИЕ УСЛОВИЯ ЗАДАЧИ

Построить ДДП, сбалансированное двоичное дерево (АВЛ) и хеш-таблицу по указанным данным. Сравнить эффективность поиска в ДДП в АВЛ дереве, в хеш-таблице (используя открытую или закрытую адресацию) и в файле. Вывести на экран деревья и хеш-таблицу. Подсчитать среднее количество сравнений для поиска данных в указанных структурах. Произвести реструктуризацию хеш-таблицы, если среднее количество сравнений больше указанного. Оценить эффективность использования этих структур (по времени и памяти) для поставленной задачи. Оценить эффективность поиска в хеш-таблице при различном количестве коллизий.

Описание технического задания

В текстовом файле содержатся целые числа. Построить ДДП из чисел файла. Вывести его на экран в виде дерева. Сбалансировать полученное дерево и вывести его на экран. Построить хеш-таблицу из чисел файла. Использовать закрытое хеширование для устранения коллизий. Осуществить

добавление введенного целого числа, если его там нет, в ДДП, в сбалансированное дерево, в хеш-таблицу и в файл. Сравнить время добавления, объем памяти и количество сравнений при использовании различных (4-х) структур данных. Если количество сравнений в хеш-таблице больше указанного(вводить), то произвести реструктуризацию таблицы, выбрав другую функцию.

Входные данные:

1. Целое число, представляющее собой номер команды:

целое число в диапазоне от 0 до 4.

Выходные данные:

1. Результат выполнения команды.
2. Сообщение об ошибке.

Функции программы:

Меню

- 1 – Загрузить данные из файла
- 2 – Вывести деревья и хеш-таблицу
- 3 – Добавить элемент
- 4 – Сравнить эффективность СД
- 5 – Эффективность реструктуризации
- 0 – Выход

Обращение к программе:

Запуск через терминал (./app.exe)

Аварийные ситуации:

1. Некорректный ввод номера команды.

На вход: число, большее чем 5 или меньшее, чем 0.

На выход: *«Неверная команда.»*

ОПИСАНИЕ СТРУКТУРЫ ДАННЫХ

Структуры

```
// узел дерева
typedef struct node
{
    int data; // данные, хранящие в узлах
    int height; // высота дерева в узле
    struct node* left; // указатель на левую ветку
    struct node* right; // указатель на правую ветку
} node_t;
```

```
// ячейка хэш-таблицы
typedef struct
{
    int flag; // показатель, что ячейка занята
    int value; // данные ячейки
} cell_t;
```

```
// хэш-таблица
typedef struct
{
    cell_t *data; // ячейка
    int limit; // количество коллизий
    int size; // текущий размер таблицы
    int max_size; // максимальный размер таблицы
} hash_t;
```

Макрозамены

```
#define TRUE 1
#define FALSE 0
#define LIMIT 15
#define SIZE 15
```

Хэш-функция:

```
// остаток от деления числа на размер таблицы
int hash_function(int key, int table_size)
{
    key > 0 ? (key) : (key *= -1);
    return key % table_size;
}
```

НАБОР ТЕСТОВ

	Название теста	Пользователь вводит	Вывод
1	Некорректный ввод команды	5 &^%	Неверная команда.
2	Выбор из пункта 1	3	Неверно выбор файл.
3	Вызов пункта 2 до вызова 1		Данные для построения дерева не были загружены. Выберите пункт 1.
4	Вызов пункта 3 до вызова 1		Данные для построения дерева не были загружены. Выберите пункт 1.
5	Вызов пункта 4 до вызова 1		Данные для построения дерева не были загружены. Выберите пункт 1.
6	Ввод добавляемого числа (пункт 3)	У .,: ^%	Ошибка ввода.
7	Ввод количества генерируемых	У .,: ^%	Неверное количество

	чисел в файле (пункт 1.2)		генерируемых чисел.
8	Ввод добавляемого числа (пункт 4)	У .,: ^%	Ошибка ввода.
9	Попытка открыть несуществующий файл (пункт 1)		Ошибка открытия файла.

ОЦЕНКА ЭФФЕКТИВНОСТИ

Оценивается время (в тактах), количество сравнений и память (в байтах) при добавлении элемента в различные структуры данных.

Количество элементов: 10

	Время	Сравнения	Память
ДДП	3	4	240
АВЛ	2	4	240
Хэш-таблица	2	1	112
Файл	12	11	35

Количество элементов: 50

	Время	Сравнения	Память
ДДП	4	3	1200
АВЛ	3	4	1200
Хэш-таблица	2	1	432
Файл	14	51	175

Количество элементов: 100

	Время	Сравнения	Память
ДДП	5	5	2400
АВЛ	5	6	2400
Хэш-таблица	2	1	832
Файл	30	101	360

ОЦЕНКА ЭФФЕКТИВНОСТИ РЕСТРУКТУРИЗАЦИИ

Были созданы три файла, содержащие числа, кратные максимально возможному размеру таблицы (15). Первый файл содержит 12 чисел, второй – 20, третий – 50. Необходимо сравнить эффективность по времени реструктуризации таблицы. Реструктуризация не будет происходить, если максимально возможное количество сравнений будет превышать количество чисел, кратных размеру таблицы (в нашем случае, она может быть >51).

Для каждого из файлов производится замер времени без реструктуризации и с ней - при трех максимально возможных количествах сравнений: 10, 5, 2. Время измеряется в тактах.

Сравнений	12 элементов		20 элементов		50 элементов	
Реструктуризация	-	+	-	+	-	+
10	24	40	19	131	57	347
5	13	58	26	124	59	988
2	37	113	30	236	63	1020

КОНТРОЛЬНЫЕ ВОПРОСЫ

1. Что такое дерево?

Дерево – это нелинейная структура данных, используемая для представления иерархических связей, имеющих отношение «один ко многим». Дерево с базовым типом Т определяется рекурсивно либо как пустая структура (пустое дерево), либо как узел типа Т с конечным числом древовидных структур этого же типа, называемых поддеревьями.

2. Как выделяется память под представление деревьев?

Способ выделения памяти под деревья определяется способом их представления в программе. С помощью матрицы или списка может быть реализована таблица связей с предками или связный список сыновей. Целесообразно использовать списки для упрощенной работы с данными, когда элементы требуется добавлять и удалять, т. е. выделять память под каждый элемент отдельно. При реализации матрицей память выделяется

статически.

3. Какие стандартные операции возможны над деревьями?

Основные операции с деревьями: обход дерева, поиск по дереву, включение в дерево, исключение из дерева. Обход вершин дерева можно осуществить следующим образом:

- сверху вниз (префиксный обход)
- слева направо (инфиксный обход)
- снизу вверх (постфиксный обход)

4. Что такое дерево двоичного поиска?

Дерево двоичного поиска – дерево, в котором все левые потомки моложе предка, а все правые – старше. Это свойство называется характеристическим свойством дерева двоичного поиска и выполняется для любого узла, включая корень. С учетом этого свойства поиск узла в двоичном дереве поиска можно осуществить, двигаясь от корня в левое или правое поддерево в зависимости от значения ключа поддерева.

5. Чем отличается идеально-сбалансированное дерево от AVL дерева?

Узлы при добавлении в идеально сбалансированное дерево располагаются равномерно слева и справа. Получается дерево, у которого число вершин в левом и правом поддеревьях отличается не более, чем на единицу. В то время как AVL-дерево – сбалансированное двоичное дерево, у каждого узла которого высота двух поддеревьев отличается не более чем на единицу.

6. Чем отличается поиск в AVL-дереве от поиска в дереве двоичного поиска?

Временная сложность поиска элемента в АВЛ дереве – $O(\log_2 n)$

Временная сложность поиска элемента в дереве двоичного поиска – от $O(\log_2 n)$ до $O(n)$.

7. Что такое хеш-таблица, каков принцип ее построения?

Массив, заполненный в порядке, определенном хеш-функцией, называется хеш-таблицей. Функция, по которой можно вычислить этот индекс, называется хеш-функцией. Принято считать, что хорошей является такая функция, которая удовлетворяет следующим условиям:

- функция должна быть простой с вычислительной точки зрения;
- функция должна распределять ключи в хеш-таблице наиболее равномерно.
- функция должна минимизировать число коллизий

8. Что такое коллизии? Каковы методы их устранения.

Коллизия - ситуация, когда разным ключам соответствует одно значение хеш-функции, то есть, когда $h(K_1) = h(K_2)$, в то время как $K_1 \neq K_2$. Существует два метода разрешения этой проблемы.

Первый метод – внешнее(открытое) хеширование (метод цепочек). В случае, когда элемент таблицы с индексом, который вернула хеш-функция, уже занят, к нему присоединяется связный список. Таким образом, если для нескольких различных значений ключа возвращается одинаковое значение хеш-функции, то по этому адресу находится указатель на связанный список, который содержит все значения.

Второй метод - внутреннее (закрытое) хеширование (открытая адресация). Оно состоит в том, чтобы полностью отказаться от ссылок. В этом случае, если ячейка с вычисленным индексом занята, то можно просто просматривать следующие записи таблицы по порядку (с шагом 1), до тех

пор, пока не будет найден ключ K или пустая позиция в таблице.

9. В каком случае поиск в хеш-таблицах становится неэффективен?

Поиск в хеш-таблицах становится менее эффективен, если наблюдается большое число коллизий. Тогда вместо ожидаемой сложности $O(1)$ получим сложность $O(n)$.

В случае открытого хеширования (цепочки) поиск в списке осуществляется простым перебором, так как при грамотном выборе хеш-функции любой из списков оказывается достаточно коротким. Если же хеширование закрытое, необходимо просматривать все ячейки, если есть много коллизий.

10. Эффективность поиска в AVL деревьях, в дереве двоичного поиска и в хеш-таблицах

Хеш-таблица - от $O(1)$ до $O(n)$

AVL-дерево - $O(\log_2 n)$

Дерево двоичного поиска – от $O(\log_2 n)$ до $O(n)$.

ВЫВОД

Основным преимуществом деревьев является возможная высокая эффективность реализации основных на ней алгоритмов поиска и сортировки. При удалении или добавлении элемента необходимо корректировать балансировку, тем самым это занимает время.

Хеш-таблицы используют меньше памяти, и для них требуется меньшее количество операций сравнения при добавлении. Так же таблицы требуют качественной хеш-функции, чтобы избежать большого количества коллизий.

Из переведенной выше оценки эффективности можно сделать вывод, что лучше всего и по памяти, и по времени работает хеш-таблица. Это объясняется тем, что для того, чтобы в сбалансированное бинарное дерево добавить элемент, необходимо так же сделать балансировку, что занимает время. Так же, когда мы храним данные в таблице, мы не используем указатели, как в случае с деревьями, поэтому память у хеш-таблицы меньше.

Так же можно заметить, что сбалансированное дерево не всегда выигрывает у несбалансированного. Проигрывает во времени, так как порядок вершин всегда меняется, но выигрывает в сравнении (по среднему количеству сравнений добавления), так как высота сбалансированного дерева будет меньше или такой же, как и у несбалансированного, поэтому чтобы узнать месторасположение элемента, приходится меньше ходить по дереву.